

Réalisez un traitement dans un environnement Big Data sur le Cloud

Armand FAUGERE Linked in armand-faugere@live.fr

Sommaire

- I) Cadrage du projet et données d'entrée
- II) Mise en place de l'environnement big data
- III) Mise en œuvre du traitement
- IV) Conclusion





I) Cadrage du projet et données d'entrée



☐ Contexte:

- solutions innovantes pour la récolte de fruits
- application mobile avec prise de photo et identification du fruit
- → Sensibiliser à la diversité des fruits
- → Première version du moteur de classification des images de fruits
- → Travaux de traitement initial réalisés et à utiliser

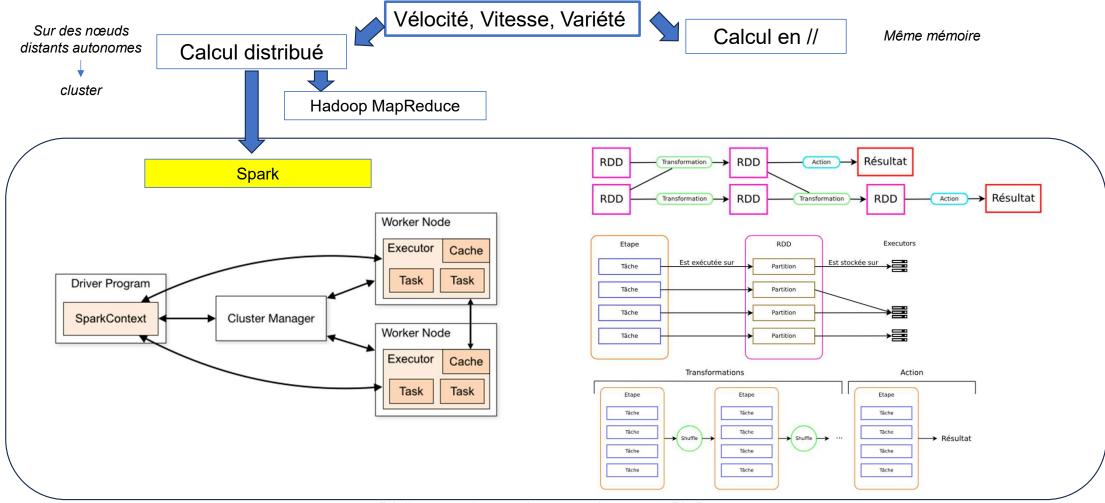
☐ But:

- Réaliser une démonstration de la mise en place d'une instance EMR opérationnelle
- □ Objectifs:
- S'approprier le travail déjà réalisé
- Respecter le principe RGPD
- Mettre en œuvre une solution de traitement en local
- Préparer l'environnement de traitement big data
- Mettre en œuvre la solution de traitement via une instance EMR
- Réaliser une conclusion

- → Un notebook réalisé sous linux (Ubuntu)
- → https://www.kaggle.com/datasets/moltean/fruits
- The total number of images: 90483.
- Training set size: 67692 images (one fruit or vegetable per image).
- Test set size: 22688 images (one fruit or vegetable per image).
- The number of classes: 131 (fruits and vegetables).
- Image size: 100x100 pixels











Google colab, pyspark, pyarrow, io, os, tensorflow, Jupiter Notebook, Python, pandas, numpy,



Mise en place google colab / drive



Ajustement du notebook



Test en local



Ajustement notebook et

test en local

1

- création d'un dossier google drive
- ☐ Mise en place des liens dans le notebook
- exécution du notebook

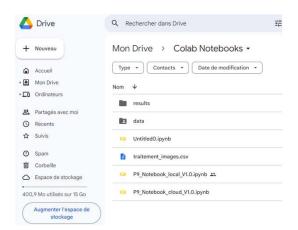


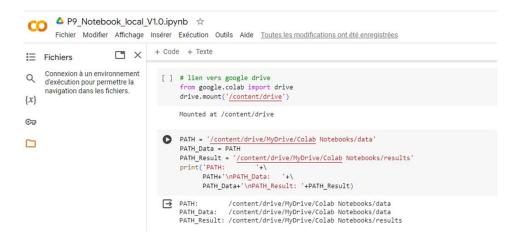
- □ Vérification des fonctions
- ☐ Ajout d'une réduction de dimension (pca)

☐ Test du notebook avec enregistrement des images dans un répertoire results

Ajustement notebook et Test en local





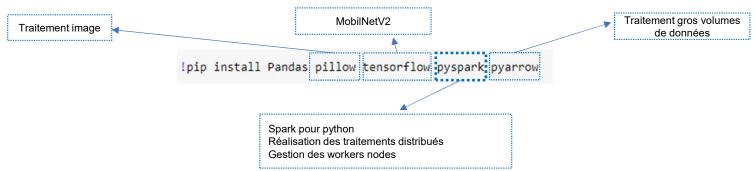


Espace documentaire google drive

Mise en place des liens



Ajustement notebook et Test en local



```
import pandas as pd
from PIL import Image
import numpy as np
import io
import os

import tensorflow as tf
from tensorflow.keras.applications.mobilenet_v2 import MobileNetV2, preprocess_input
from tensorflow.keras.preprocessing.image import img_to_array
from tensorflow.keras import Model
from pyspark.sql.functions import col, pandas_udf, PandasUDFType, element_at, split
from pyspark.sql import SparkSession
```

```
from pyspark.ml.feature import PCA
from pyspark.ml.functions import array_to_vector
from pyspark.ml.functions import vector_to_array
```

Ajustement notebook et Test en local



```
spark = (SparkSession
             .builder
             .appName('P9')
                                                                                 SparkSession (driver process)
             .master('local')
             .config("spark.sql.parquet.writeLegacyFormat", 'true')
             .getOrCreate()
                                         Objet pour gérer les propriétés
 sc = spark.sparkContext
                                         globales de l'application
  images = spark.read.format("binaryFile") \
    .option("pathGlobFilter", "*.jpg") \
    .option("recursiveFileLookup", "true") \
    .load(PATH_Data)
                                                                                               Chargement des images
  images = images.withColumn('label', element_at(split(images['path'], '/'),-2))
  print(images.printSchema())
  print(images.select('path','label').show(5,False))
```

Ajustement notebook et Test en local



| Input | Operator | t | c | $\mid n \mid$ | s |
|----------------------|-------------|---|------|---------------|---|
| $224^{2} \times 3$ | conv2d | - | 32 | 1 | 2 |
| $112^2 \times 32$ | bottleneck | 1 | 16 | 1 | 1 |
| $112^{2} \times 16$ | bottleneck | 6 | 24 | 2 | 2 |
| $56^{2} \times 24$ | bottleneck | 6 | 32 | 3 | 2 |
| $28^2 \times 32$ | bottleneck | 6 | 64 | 4 | 2 |
| $14^{2} \times 64$ | bottleneck | 6 | 96 | 3 | 1 |
| $14^{2} \times 96$ | bottleneck | 6 | 160 | 3 | 2 |
| $7^{2} \times 160$ | bottleneck | 6 | 320 | 1 | 1 |
| $7^2 \times 320$ | conv2d 1x1 | - | 1280 | 1 | 1 |
| $7^2 \times 1280$ | avgpool 7x7 | - | _ | 1 | - |
| $1\times1\times1280$ | conv2d 1x1 | - | k | - | |

```
brodcast_weights = sc.broadcast(new_model.get_weights())

def model_fn():
    Returns a MobileNetV2 model with top layer removed and broadcas()) Mise en place de d'environn...

model = MobileNetV2(weights='imagenet', include_top=True, input_shape=(224, 224, 3))

for layer in model.layers:
    layer.trainable = False
    new_model = Model(inputs=model.input, outputs=model.layers[-2].output)
    new_model.set_weights(brodcast_weights.value)
    return new_model
```

Aiustement notebook et Test en local



Preprocesing + Extraction features

```
def preprocess(content):
    Preprocesses raw image bytes for prediction.
    img = Image.open(io.BytesIO(content)).resize([224, 224])
    arr = img_to_array(img)
    return preprocess_input(arr)
def featurize series(model, content series):
    Featurize a pd.Series of raw images using the input model.
    :return: a pd.Series of image features
    input = np.stack(content_series.map(preprocess))
    preds = model.predict(input)
    # For some layers, output features will be multi-dimensional tensors.
    # We flatten the feature tensors to vectors for easier storage in Spark DataFrames.
   output = [p.flatten() for p in preds]
    return pd.Series(output)
@pandas_udf('array<float>', PandasUDFType.SCALAR_ITER)
def featurize_udf(content_series_iter):
    This method is a Scalar Iterator pandas UDF wrapping our featurization function.
    The decorator specifies that this returns a Spark DataFrame column of type ArrayType(FloatType).
    :param content_series_iter: This argument is an iterator over batches of data, where each batch
                             is a pandas Series of image data.
    # With Scalar Iterator pandas UDFs, we can load the model once and then re-use it
    # for multiple data batches. This amortizes the overhead of loading big models.
    model = model_fn()
    for content series in content series iter:
       yield featurize_series(model, content_series)
```

Exécution des fonctions

```
features_df = images.repartition(20).select(col("path"),
                                           featurize udf("content").alias("features"),
                                           featurize_udf("content").alias("features_vectors")).withColumn("features_vectors", array_to_vector("features_vectors"))
```



features df.show(5, True)

| path | label | features | features_vectors |
|---------------------|----------------------|---------------|--------------------|
| ·+- | | + | |
| file:/content/dri | Carambula [0.0017 | 966835, 0 [6 | 0.00179668352939 |
| file:/content/dri | Carambula [0.0630 | 4055, 0.0, [6 | 0.06304054707288 |
| file:/content/dri | Avocado [0.4538 | 4294, 0.0, [6 | 3.45384293794631 |
| file:/content/dri C | actus fruit [0.5492 | 1436, 0.08 [6 | 3.54921436309814 |
| file:/content/dri | Grape Blue [0.0, 0 | .0. 0.0. 0 [6 | 0.0.0.0.0.0.0.0.0. |





Réduction de dimension



| path | label | features | features_vectors | pca_vectors |
|---------------------|--------------------|----------------|-----------------------|----------------|
| file:/content/dri | Carambula [0 001 | 7066835 0 10 | 0.00179668352939 [7.6 | 2084015677402 |
| file:/content/dri | | | 0.06304054707288 [8.8 | |
| file:/content/dri | | | 0.45384293794631 [-8. | |
| file:/content/dri C | | 21436, 0.08 [6 | 0.54921436309814 [4.8 | 31757964162033 |
| file:/content/dri | Grape Blue [0.0, | 0.0, 0.0, 0 [6 | 0.0,0.0,0.0,0.0, [-19 | .470275048053 |

only showing top 5 rows

ajout d'une colonne transformé vecteur ==> array
df_pca = df_pca.withColumn('pca_features', vector_to_array('pca_vectors'))
df_pca.show(5, True)

| path | label | features | features_vectors | pca_vectors | pca_features |
|----------------------|---------------------|---------------|------------------|--------------------|-------------------|
| + | | +- | + | + | |
| file:/content/dri | Carambula [0.001 | 7966835, 0 [| 0.00179668352939 | [7.02984915677402 | [7.02984915677402 |
| file:/content/dri | Carambula [0.063 | 04055, 0.0, [| 0.06304054707288 | [8.86773941887345 | 8.86773941887345 |
| file:/content/dri | Avocado [0.453 | 84294, 0.0, [| 0.45384293794631 | [-8.1079270780534 | -8.1079270780534 |
| file:/content/dri Ca | ctus fruit [0.549 | 21436, 0.08 [| 0.54921436309814 | [4.81757964162033] | 4.81757964162033 |
| file:/content/dri | Grape Blue [0.0. | 0.0. 0.0. 0 | 0.0.0.0.0.0.0.0 | [-15.470275048053] | -15.470275048053 |

only showing top 5 rows

Enregistrement format parquet



df_pca.write.mode("overwrite").parquet(PATH_Result)



Finalisation du test local

df = pd.read_parquet(PATH_Result, engine='pyarrow')



| | | | | | | dt.head() |
|---|---|--|---|-----------------|---|-----------|
| pca_featur | pca_vectors | features_vectors | features | label | path | |
| [7.029849156774027, -3.18289154379566 -5.842 | (type" 1, 'size' None, 'indices' None, 'va | ('type': 1, 'size': None, 'indices': None, 'va | [0.0017966835, 0.0, 0.0, 0.0, 1.365782, 0.0, 0 | Carambula | file:/content/drive/MyDrive/Colab Notebooks/da | 0 |
| [8.867739418873459, -3.090568606051426 -5.75 | (type": 1, 'size': None, 'indices': None, 'va | ('type': 1, 'size': None, 'Indices': None, 'Va | [0.06304055, 0.0, 0.0, 0.0, 1.1863725, 0.0, 1 | Carambula | file /content/drive/MyDrive/Colab Notebooks/da | 1 |
| [-8.10792707805341, -7.70697007699477 -5.256 | (type': 1, 'size': None, 'indices': None, 'va | ('type': 1, 'size': None, 'indices': None, 'va | [0.45384294, 0.0, 0.011254884, 0.0, 0.01393815 | Avocado | file:/content/drive/MyDrive/Colab Notebooks/da | 2 |
| [4.81757964162033, -0.801124221834744 0.5307 | (type': 1, 'size': None, 'indices': None, 'va | ('type': 1, 'size': None, 'indices': None, 'va | [0.54921436, 0.08829143, 0.0, 0.0, 0.0, 0.06960542, | Cactus fruit | file:/content/drive/MyDrive/Colab Notebooks/da | 3 |
| [-15.470275048053912, -1.648885181903788 | (Type': 1, 'size': None, 'indices': None, 'va | (Type' 1, 'size' None, 'indices' None, 'va | [0.0, 0.0, 0.0, 0.0, 0.0, 1.375451, 0.05689891 | Grape Blue | file /content/drive/MyDrive/Colab Notebooks/da | 4 |



Cluster prêt

waiting

Environnement de traitement

AWS, S3, ECS, EMR, AWS CLI, pyspark, pyarrow, io, os, tensorflow, JupiterHub, Python, Pandas, numpy



2

Mise en place de l'environnement bigdata

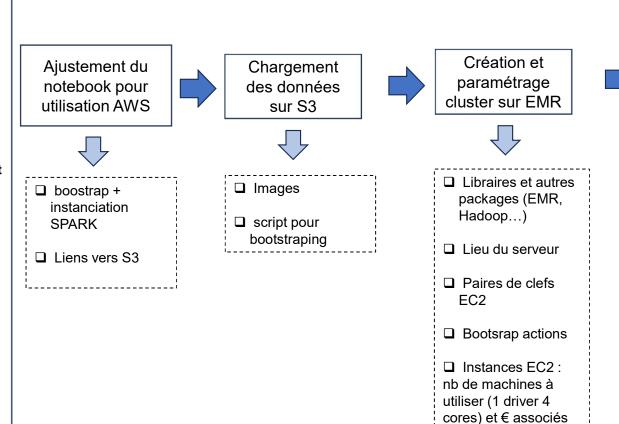




S3



IAM

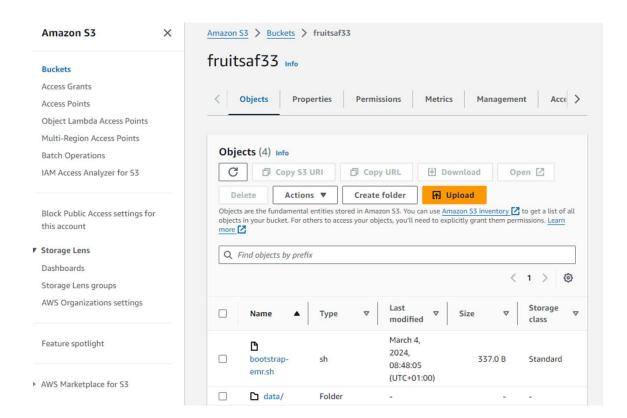


Réalisez un traitement dans un environnement Big Data sur le Cloud

Environnement de traitement



☐ Extrait de l'écran S3



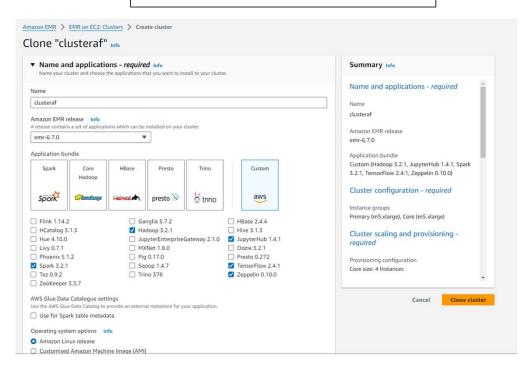
☐ AWS CLI

(projet_9_OC) PS C:\Users\ARMAN> aws s3 ls
Association de fichier introuvable pour l'extension .py
2024-03-01 18:04:32 aws-logs-905418132460-eu-west-1
2024-02-29 15:11:44 fruitsaf33
2024-03-01 16:48:09 p8-data-af
(projet_9_OC) PS C:\Users\ARMAN> |

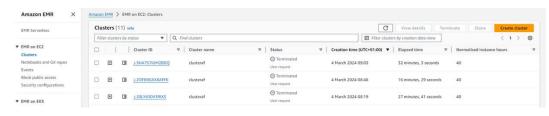
Environnement de traitement



☐ Extrait de l'écran EMR création de cluster



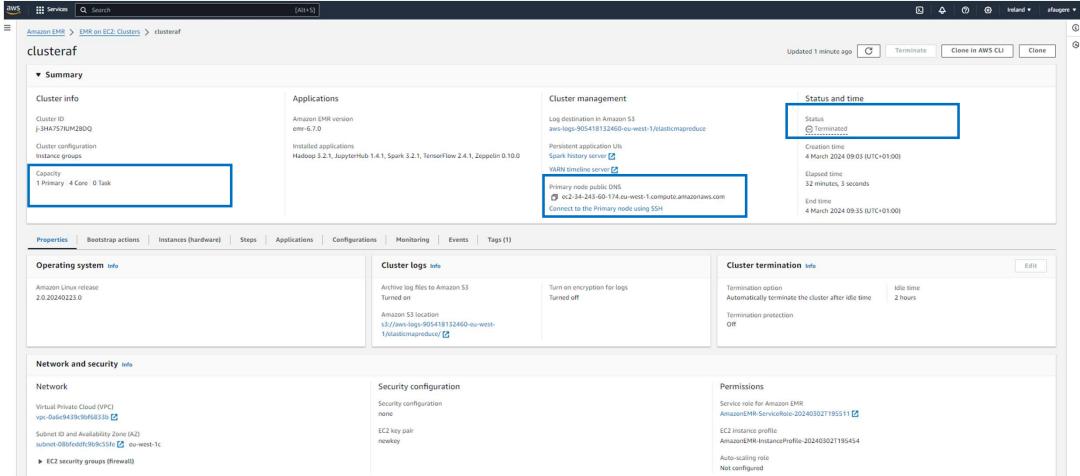
☐ Extrait de l'écran EMR de l'état des clusters



Environnement pour traitement



☐ cluster utilisé pour traitement



2024 Armand FAUGERE

Réalisez un traitement dans un environnement Big Data sur le Cloud





AWS, S3, ECS, EMR, AWS CLI, Foxyproxy, gitbash pyspark, pyarrow, io, os, tensorflow, JupiterHub, Python, Pandas, numpy



3

Traitement





S3





Création du tunnel SSH



Exécution de l'application



Clôture cluster







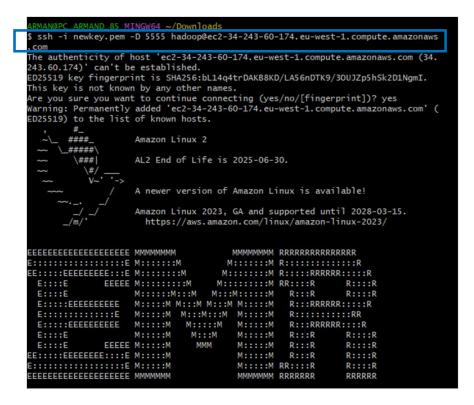
- ☐ Connexion au nœud primaire :
- groupe de sécurité EC2 (ouverture port 22)
- récupération de la clef crée pour le cluster → .pem
- commande aws + clef + port 5555 -D



- ☐ Activation jupyterHub
- □ Activation foxyproxy
- ☐ Exécution du code
- ☐ Surveillance de l'éxecution





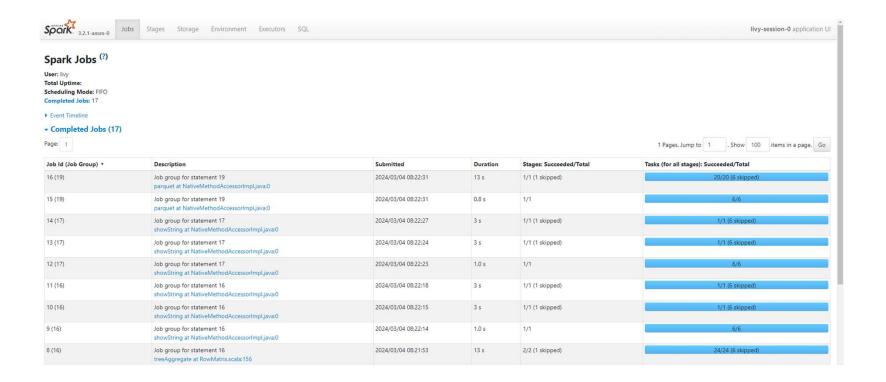




Création du tunnel SSH

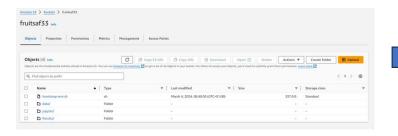


Suivi de l'historique

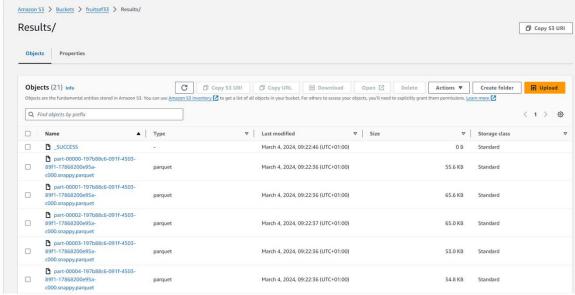




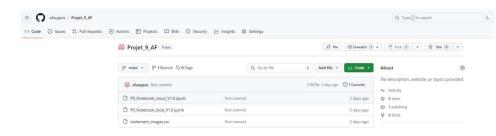
Répertoire S3





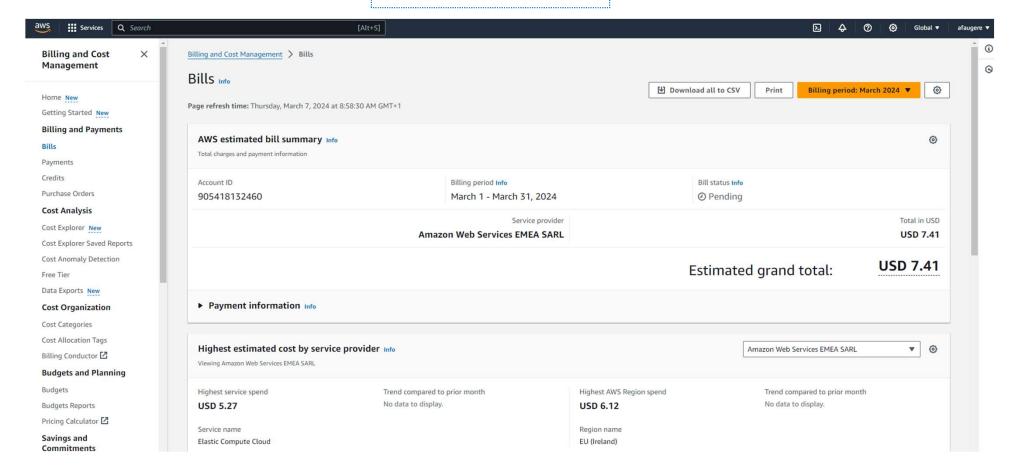


Repository github



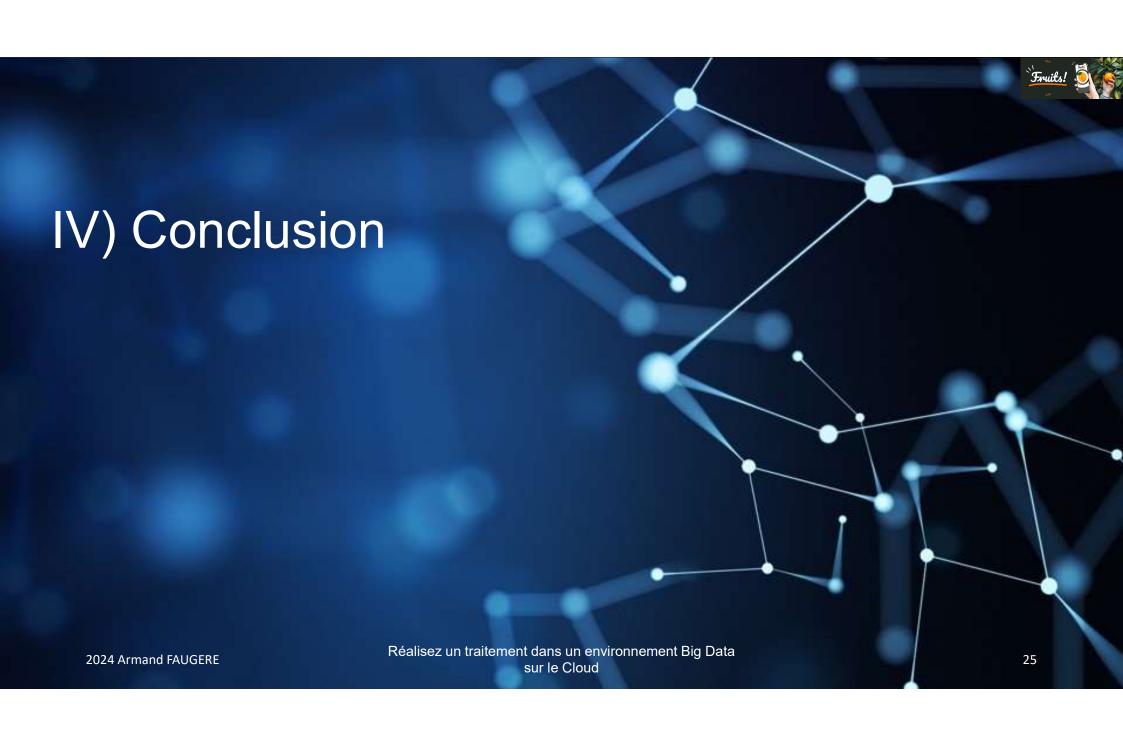


Facturation AWS





Démonstration du script en ligne AWS



IV) Conclusion



☐ Rappel Contexte :

- solutions innovantes pour la récolte de fruits
- application mobile avec prise de photo et identification du fruit
- → Sensibiliser à la diversité des fruits
- → Première version du moteur de classification des images de fruits
- Travaux de traitement initial réalisés et à utiliser

Forces

- ☐ Fonctionne sur le cloud pour notre projet
- ☐ Flexibilité (adaptation de la puissance de calcul et autres ressources)
- ☐ Suivi complet et instantané (opérations de traitement, facturation...)
- Ergonomie de la solution AWS
- □ Sécurité

Risques

☐ Perte financière si mauvaise gestion de la solution

Faiblesses

☐ Facturation à la seconde, les € peuvent augmenter rapidement

Opportunités

- ☐ Piloter le déploiement de la solution en mode progressif et en adaptant les ressources
- ☐ Suivre les dépenses réalisés vs « chiffre d'affaires réalisé »
- ☐ Mettre en place une gestion piloté de la solution

IV) Conclusion



| Réaliser une dé | monstration de la mise en place d'une instance EMR opérationnelle | 0 0 |
|--|---|-----|
| S'approprier le travail déjà réalisé | Le notebook existant a été réutilisé et adapté à la problématique | •• |
| Respecter le principe RGPD | Utilisation du serveur européen et de clefs de sécurité | 0 0 |
| Mettre en œuvre une solution de traitement en local | Mise au point de la solution de traitement en local avec googlecolab | 0 0 |
| Préparer l'environnement de traitement big data | Environnement de traitement mis au point avec AWS (cluster configuré), et froxyproxy | 0 0 |
| Mettre en œuvre la solution de traitement via une instance EMR | Mise en ouevre de la solution de traitement avec enregistrement des résultats et historique de traitement | 0 0 |
| Réaliser une conclusion | Une synthèse a été réalisée | 0 0 |

Merci

- Armand FAUGERE
- armand-faugere@live.fr

